



Strompreis-Vorhersage Deutschland

Folgeprojekt von Stromverbrauch-Vorhersage

Machine Learning für stündliche Strompreis-Prognosen · Wetter · Kalender · SMARD

SMARD API

Marktdaten

MaStR

PV- u. Windanlagendaten

OPEN-METEO

Wetterdaten


Streamlit App

Output

Projektziel belastbare 24h-Preisprognose



Ziel ist eine Prognose, die im Tagesbetrieb interpretierbar und mit offiziellen Markt- und Wetterdaten vergleichbar ist.




Rekursive Machine Learning Ablauf

- Historische Vorhersage nutzt die historische Daten aus SMARD
- Vorhersage für morgen setzt auf die Vorhersage der Stromverbrauch, PV und Wind Energie-Erzeugung und die Wettervorhersage als Prädiktoren
- Durch die Visualisierung werden signifikante Abweichungen entdeckt. Daraufhin werden neue Features dafür gebildet und die Modelle neu trainiert.

Datenbasis historische Erzeugung + Last + Wetter + Kalender



Die Prognose basiert auf gestapelter Vorhersage von Stromerzeugung, Stromverbrauch und Wetter(aus open-meteo).



MaStR

Stromerzeuger bis Mai 2026
Cluster aus Koordinaten und
Leistungen als Gewichte

Open-Meteo

Historische Wetterdaten
nach Erzeuger-Cluster gewichtet

Gestapelte Vorhersage




Vorhersage für morgen hänge von
Stromerzeugungs- und
Stromverbrauchsvorhersage ab

SMARD + OPEN-METEO API

Historische Daten
offizielle Vorhersage + Prognose



	MaStrR	SMARD	OPEN-METEO
Daten	MaStrR - Marktstammdatenregister	Netzlast-Marktdaten	Wetterdaten
Source	marktstammdatenregister.de	Bundesnetzagentur SMARD.de	Open-Meteo open-meteo.com
Lizenz	DL-DE->BY-2.0	CC BY 4.0	CC BY 4.0

EDA Saison, Trend und zeitliche Effekte



Erkenntnisse

- Analog zu dem Stromverbrauch haben die Strompreise auch deutliche Stunden-, Wochentages-, Monats-Saisonalität.
- Der Strompreis ist gegenüber dem Stromverbrauch tendenziell leicht steigend.




RANSAC Regressor

- RANSAC mit conventional_gen_mwh als Referenz trainiert und potentielle Ausreißer identifiziert


Erkenntnisse

- Mit empirischem und RANSAC Regression (basiert auf konventioneller Stromerzeugung) werden Ausreißer identifiziert
- Extreme hohe Preise: Energiekrise August 2022, Ende 2025 - gestiegene Netzentgelte, hohe Beschaffungskosten an den Energiebörsen, Ende der Subvention
- Negative Preise: saisonal(früh Sommer) niedriger Verbrauch, zunehmende PV Anlage, mangelnde Stromspeicherkapazität
- Die Datenpunkte sind jedoch plausibel und nicht für die Zukunft abbildbar, und werden daher nicht behandelt

Aggregation der Wetterdaten für PV- und Wind-Energieerzeugung



PV-Anlagen Cluster



Wind-Anlagen Cluster

Berechnung der Wetterdaten:

- Die PV und Wind (Offshore + Onshore) Anlagen Daten mit Nettoleistung und Betriebsnahmendatüme aus MaStrR
- Mit KMeans jeweils 10 Cluster gebildet. Die Koordinaten der Centroids für Wetterdaten-anfrage verwendet
- Die Wetterdaten (Windgeschwindigkeit auf 100 Meterhöhe, Sonnenstrahlung, Wolkendeckung) aus open-meteo
- Wetterdaten mit jeweiliger jährlichen Kapazitäten gewichtet


Erkenntnisse

- PV Anlagen liegen vorwiegend im Osten des Landes. Norden und Süden sind relativ ausgeglichen
- Wind-Erzeugung stammt in erster Linie aus dem Norden. Die Offshore Windanlage haben die größten Kapazitäten.

Feature Engineering – Kombination aus verschiedenen Quellen



Die (37) Features aus historischen Markt-, Wetterdaten, Wettervorhersagen und Feature Engineering



Erkenntnisse:

- Mehr Features führen nicht unbedingt zu besserer Vorhersage, eventuell so gar Over-Engineering
- Aggregierte Features aus Kombinationen der anderen Features helfen nur bedingt



Modellvergleich XGBoost vs LightGBM



Modell	MAE	RMSE	R ²	Trainingsdauer (Bayesian Optimization)
XGBoos	15.27	24.07	0.82	13'39"
LightGBM	15.68	24.58	0.81	1'32"

Lernkurven:

- Validierungsfehler sinkt mit mehr Daten, stagniert bei 14000 Datenpunkt.
- Der Lücke zum Trainingsfehler bleibt sichtbar.




Erkenntnisse

- XGBoost liefert die beste MAE und R², LightGBM ist schneller.

Feature Importances



Permutation Feature Importance (MAE) - Top 15 Features




Erkenntnisse

- Beide Modelle verweisen die Wichtigkeit auf ähnlichen Features
- Wind-Erzeugung, historische Preise, Stromverbrauch und Wetterdaten spielen die größten Rolle

Hinweis

Feature Importance nicht als Kausalität interpretieren

Tagesprognose Vergleich mit Residuallast und historischen Preise



Anwendung

- Tagesprognose Vergleich mit dem Durchschnitt der letzten 7 Tage und der Residuallast für die Interpretierbarkeit und die Plausibilität
- Modellauswahl
 - LightGBM
 - XGBoost

ML morgen
Prognose

7 Tage mean
Realpreis


Vorgestern
Realpreis

Residuallast =
PV + Wind - Verbrauch
Prognose

Erkenntnis

- Tagesvorhersage folgt dem täglichen Muster von Vorgestern und 7 Tage Durchschnitt
- **XGB sagt deutlich die Realität nahe Preise voraus und ist der eindeutige Gewinner**

Historischer Vergleich Vorhersage vs Reale Preise



Anwendung

- Zeitraum auswählen
- Metriken
- Abweichungen erkennen
- Historische Werte und Vorhersage können als csv heruntergeladen werden

ML morgen
Prognose

Historische
Realpreis

MAE	RMSE	R ²	Datenpunkte
17.41 €/MWh	25.28 €/MWh	0.82	408



Erkenntnis

- Tagesvorhersage folgt dem täglichen Muster
- Einzelne Abweichungen erkennbar, erfordern weitere Analyse.

Fazit und Folgeprojekt



Projektfazit

- Aggregation der Wetterdaten anhand der Erzeuger und deren Kapazitäten führt zu genauer Vorhersage der Energie-Erzeugung
- Datenlücke erzwingen die Preise mit Erzeugung- und Verbrauchsvorhersage zu prognostizieren
- Die Features für Zeit, Wetter, Erzeugung und historische Preise bzw. die Lag und Rolling Features fließen als Prädiktoren ein
- Feature Engineering (Kombinationen) führt zu leicht Verbesserung

Verbesserungspotential

- Walk-Forward-Simulation für historische Vorhersage für genaueres Scoring
- Automatisch Erzeugerdaten aus MaStR holen und die Wettergewichtungen aktualisieren
- Automatisches Modelltraining mit neu gewonnenen Daten
- Weitere Daten aus SMARD als Features
- Power BI Dashboard erstellen

To be continued: **Ausfallvorhersage – Turbofan Engine Predictive Maintenance (NASA CMAPSS)**