



Stromverbrauch- Vorhersage Deutschland

Machine Learning für stündliche Netzlast-Prognosen · Wetter · Kalender · SMARD-Vergleich

2019–24 / 2025

Train/Test Split

SMARD API

Aktualisierung

Streamlit App

Output

Projektziel: belastbare 24h-Lastprognose

Ziel ist nicht nur ein hoher R^2 -Wert, sondern eine Prognose, die im Tagesbetrieb interpretierbar und mit offiziellen SMARD-Werten vergleichbar ist.




Rekursive ML Ablauf

- Von Problem → Daten → Features → Modell → Anwendung
- MAE/RMSE und Fehlerbilder stärker betonen als nur R^2
- Feature Engineering trägt mehr zu der Vorhersage bei als die Modellselektion
- Feature Selektion nach Feature Importance Analysis
- Parameter Tuning und Interaktive GUI → Überarbeitung der Funktionalität
- Verschiedenen Zeitformate verursacht Synchronisationsprobleme

Datenbasis: historische Last + Wetter + Kalender

Die Prognose kombiniert langfristige Verbrauchsmuster mit kurzfristigen Wetter- und Kalendereffekten.



Kaggle

Stündliche Lastdaten
CountryCode = DE

Open-Meteo

Historisches Wetter
Top-5-Städte nach Population
gewichtet

python-holidays

Feiertage, Brückentage,
Bundesland-Anteil







SMARD API

Aktuelle Netzlast +
offizielle Prognose

Glaubwürdigkeit:

Datenlizenzen/Attribution (ENTSO-E, CC BY-SA 4.0)






EDA: Saison, Trend und zeitliche Verteilung und Effekte



Erkenntnisse

- Der Stromverbrauch hat deutliche Stunden-, Wochentages-, Monats-Saisonalität.
- Der Verbrauch an arbeitsfreien Tage deutlich niedriger als sonst.
- Langzeit-Trend ist in langen Zyklen enthalten. Für Langzeitprognose muss diese berücksichtigt werden.

EDA: Wettereinfluss auf Stromverbrauch



Erkenntnisse

- Der Stromverbrauch hat Zusammenhang mit der Temperatur, Sonnenstrahlung und Windgeschwindigkeit.
- Der Niederschlag spielt eher eine kleine Rolle und fügen womöglich Rauschen in das Modell ein

Feature Engineering: starke Signale statt Modellkomplexität

Die größte Qualitätssteigerung entsteht durch saubere Zeitreihenfeatures und Lecksichere Rolling-Werte.

Zeit & Kalender

- hour, weekday, month
- is_weekend, is_workday
- is_holiday, is_bridge_day
holiday_ratio, holiday_weight
- is_pandemic_time

Wetter

- apparent_temperature
- rain / snowfall
- wind_speed_10m
- shortwave_radiation
- heating/cooling_degree

Historie



- lag_24h, lag_168h
- rolling_mean_24h
- rolling_mean_168h
- shift(24) gegen Leakage
- wichtigste Features

Eventuelle Erweiterungen:

Feiertagsnamen, Schulferienratio und ggf. Industrieproduktionsindex (für Langzeitprognose)

Modellvergleich: XGBoost/LightGBM liegen nahe beieinander

Modell	MAE	RMSE	R ²	Dauer
XGBoost	1156.96	1500.81	0.97	10'55"
LightGBM	1219.06	1604.48	0.97	2'30"




Lernkurven:

- Validierungsfehler sinkt mit mehr Daten
- Der Gap zum Trainingsfehler bleibt aber sichtbar.

Interpretation

- Beide Modelle profitieren stark von Lag-/Rolling-Features.
- XGBoost liefert die beste MAE, LightGBM ist fast gleich gut und schneller.

Feature Importances: Vorwoche schlägt Wetter




Erkenntnisse

- Verbrauch der Vorwoche (`lag\_168h`) ist der stärkste Saisonalitätsanker.
- Tageswerte (`lag\_24h`) und Rolling Means stabilisieren kurzfristige Schwankungen.
- Wetterfeatures liefern Zusatzsignal, aber erklären nicht alles.

Hinweis

Feature Importance nicht als Kausalität interpretieren

Tagesprognose für morgen: Interactive Notebook/Streamlit



Nutzen der GUI

- Tagesprognose sofort sichtbar
- SMARD-Prognose als Referenz
- Tabellarische Werte für Export/Prüfung
- Modellwechsel möglich

SMARD

Vergleichslinie


ML

Prognose

Erkenntnis

Tagesvorhersage folgt dem täglichen Muster. SMARD Prognose ist höher als die Vorhersage, eher konservativ.

Historischer Vergleich: Real vs. SMARD vs. ML



Series	MAE (MWh)	RMSE (MWh)	Points
ML Prediction (LGBM)	1,407	1,762	456
SMARD official forecast	2,626	3,280	456

Nutzen der GUI

- Anfang und Ende der Zeit für die Vorhersage.
- Man kann zwischen drei Modelle – LightGBM, XGBoost und LightGBM_conservative auswählen
- Empfehlung: Feiertage und Ferienzeiten auswählen für die Sonderfällen
- Vergleich mit SMARD Prognose

MAE

Primäre Metrik


RMSE

Nebenmetrik

Erkenntnis

Tagesvorhersage folgt dem täglichen Muster. SMARD Prognose ist höher als die Vorhersage, eher konservativ.

Konservative Vorhersage: mehr Puffer



Series	MAE (MWh)	RMSE (MWh)	Points
ML Prediction (LGBM_conservative)	1,850	2,331	552
SMARD official forecast	2,582	3,218	552

Neues Modell:

- Mit asymmetrischer Verlust werden die Modelle trainiert
- Mit Parameter Alpha=0.95, spricht, 5% Unterschätzung
- Die Metriken werden dadurch verschlechtert
- Wähle Modell: LGBM_conservative

MAE

Primäre Metrik

RMSE

Nebenmetrik

Erkenntnis

Weniger Unterschätzung für die Netzbetreiber. SMARD Prognose enthält vermutlich noch statische Offset zu mehr Sicherheit

Fazit und Folgeprojekt

Projektfazit

- Das Projekt ist als Portfolio-Projekt gut positioniert: echte Daten, klare Pipeline, Modellvergleich und Demo-App.
- Lag-/Rolling-Features sind der zentrale Performance-Treiber.
- XGBoost/LightGBM sind derzeit die stärksten Kandidaten.
- Der SMARD-Vergleich macht das Ergebnis praxisnah.
- Die Diagnose in der Produktion ist eher konservativ

Nächste Schritte

- Datenaufbereitung und Aktualisierung durch automatische ETL Pipeline erweitern
- Feiertags-/Brückentagsfehler separat evaluieren und Feature-Set erweitern.
- Schulferienratio und Industrieproduktionsindex testen.

To be continued:

Vorhersage der Residuallast

$\text{Residuallast} = \text{Netzlasterzeugung} - \text{PV} - \text{Wind} - \text{konventionelle Erzeugung}$