


Stromverbrauch-Vorhersage Deutschland



Machine Learning für stündliche Netzlast-Prognosen · Wetter · Kalender · SMARD-Vergleich

2025-10-01

Train/Test Split

SMARD API

Aktualisierung

Streamlit App

Output

Projektziel: belastbare 24h-Lastprognose

Ziel ist nicht nur ein hoher R^2 -Wert, sondern eine Prognose, die im Tagesbetrieb interpretierbar und mit offiziellen SMARD-Werten vergleichbar ist.




Rekursive Machine Learning Ablauf

- Von Problem → Daten → Features → Modell → Anwendung
- Feature Engineering trägt mehr zu der Vorhersage bei als die Modellselektion und -tuning
- Feature Selektion nach Feature Importance Analysis
- Parameter Tuning und Interaktive GUI
- Verschiedenen Zeitformate mit Zeitzone verursacht Synchronisationsprobleme
- ETL Pipeline verbessert Reaktionszeit, Datensicherheit und -konsistenz

Datenbasis: historische Last + Wetter + Kalender

Die Prognose kombiniert langfristige Verbrauchsmuster mit kurzfristigen Wetter- und Kalendereffekten.



Kaggle

Stündliche Lastdaten
CountryCode = DE

Open-Meteo

Historisches Wetter
Top-5-Städte nach Population gewichtet

python-holidays

Feiertage, Brückentage,
Bundesland-Anteil

SMARD API


Aktuelle Netzlast +
offizielle Prognose

	SMARD	OPEN-METEO
Daten	Netzlast-Marktdaten	Wetterdaten
Source	Bundesnetzagentur SMARD.de	Open-Meteo https://open-meteo.com/
Lizenz	CC BY 4.0	CC BY 4.0

Datenquelle: Verfügbarkeit bei Modell-Evaluierung



Zum Zeitpunkte der Prognose sind die Strombedarf- und Wetterdaten für den aktuellen und den Vortag noch nicht verfügbar, die erst prognostiziert werden müssen, damit die Vorhersage für den nächsten Tag auf dieser Basis getätigt werden kann.




Erkenntnisse:

- Evaluierung auf historische realen Daten wäre zu optimistisch

Datenquelle: Verfügbarkeit bei Vorhersagen für morgen











Zum Zeitpunkte der Prognose sind die Strombedarf- und Wetterdaten für den aktuellen und den Vortag noch nicht verfügbar, die erst prognostiziert werden müssen, damit die Vorhersage für den nächsten Tag auf dieser Basis getätigt werden kann.



Erkenntnisse:

- Stromverbrauch-Vorhersage für morgen in zwei Stufen umgesetzt werden






EDA: Saison, Trend und zeitliche Verteilung und Effekte



Erkenntnisse

- Der Stromverbrauch hat deutliche Stunden-, Wochentages-, Monats-Saisonalität.
- Der Stromverbrauch ist an arbeitsfreien Tage deutlich niedriger als sonst.
- Langzeit-Trend ist in langen Zyklen enthalten. Für Langzeitprognose muss diese berücksichtigt werden.

EDA: Wettereinfluss auf Stromverbrauch



Erkenntnisse

- Der Stromverbrauch hat Zusammenhang mit der Temperatur, Sonnenstrahlung und Windgeschwindigkeit.
- Der Niederschlag spielt eher eine kleine Rolle und fügt womöglich Rauschen in das Modell ein

Feature Engineering: starke Signale statt Modellkomplexität

Die größte Qualitätssteigerung entsteht durch saubere Zeitreihenfeatures und Lecksichere Rolling-Werte.

Zeit & Kalender

- hour, weekday, month
- is_weekend, is_workday
- is_holiday, is_bridge_day
- holiday_ratio, holiday_weight
- school_holiday, school_holiday_ratio
- is_pandemic_time

Wetter

- apparent_temperature
- rain / snowfall
- wind_speed_10m
- shortwave_radiation
- heating/cooling_degree

Historie

- lag_24h, lag_168h
- rolling_mean_24h
- rolling_mean_168h
- shift(1) gegen Leakage
- **wichtigste Features**

Verfügbarkeit prüfen

Erkenntnisse:



- Neue Features werden nach und nach hinzugefügt durch EDA, Feature Importances Analyse und Vorhersage-Visualisierung.
- Feature Engineering ist ein iterativer Prozess

Modellvergleich: XGBoost/LightGBM liegen nahe beieinander

Modell	MAE	RMSE	R ²	Trainingsdauer (Bayesian Optimization)
XGBoost	1449.58	1840.44	0.96	~10'50"
LightGBM	1470.21	1864.09	0.96	~3'30'

Lernkurven:


- Validierungsfehler sinkt mit mehr Daten, stagniert bei 13000 Datenpunkt.
- Der Lücke zum Trainingsfehler bleibt aber sichtbar.



Erkenntnisse

- XGBoost liefert die beste MAE, LightGBM ist fast gleich gut, aber schneller.

Feature Importances: Zeitfeatures schlagen Wetter




Erkenntnisse

- Verbrauch der Vortag ('lag_24h') und Tageszeit sind die stärkste Saisonalitätsanker
- Verbrauch der Vorwoche ('lag_168h') und Rolling Means stabilisieren kurzfristige Schwankungen
- Wetterfeatures liefern Zusatzsignal, aber erklären nicht alles.
- Arbeitsfreie Tage beeinflussen signifikant den Verbrauch

Hinweis

- Feature Importance nicht als Kausalität interpretieren

Tagesprognose für morgen: Interactive Notebook



Nutzen der GUI

- Tagesprognose sichtbar
- SMARD-Prognose als Referenz
- Tabellarische Werte für Export/Prüfung
- Modellauswahl
 - LightGBM
 - XGBoost


SMARD

Vergleichslinie



ML

Prognose

Erkenntnis

- Tagesvorhersage folgt dem täglichen Muster. ML Vorhersage ist etwas niedriger als SMARD Prognose.

Historischer Vergleich: Real vs. SMARD vs. ML



Nutzen der GUI

- Anfang und Ende der Zeit für die Vorhersage.
- Abweichungsvergleich: Feiertage und Ferienzeiten auswählen
- Vergleich mit SMARD Prognose
- Modellauswahl
 - LightGBM
 - XGBoost

Series	MAE (MWh)	RMSE (MWh)	Points
ML Prediction (XGBoost)	1481	1823	480
SMARD official forecast	2628	3252	480

MAE

Primäre Metrik


RMSE

Nebenmetrik

Erkenntnis

- Durch Visualisierung wird die Abweichungsmuster besser erkennbar. Mögliches weitere Feature Engineering für die Genauigkeitsverbesserung.

Historischer Vergleich mit Walk-Forward Evaluierung



Nutzen der GUI

- Anfang und Ende der Zeit für die Vorhersage.
- Abweichungsvergleich: Feiertage und Ferienzeiten auswählen
- Vergleich mit SMARD Prognose
- Modellauswahl
 - LightGBM
 - XGBoost

Series	MAE (MWh)	RMSE (MWh)	Points
ML Prediction (LGBM)	1,554	1,765	168
SMARD official forecast	1,777	2,153	168

MAE
Primäre Metrik


RMSE
Nebenmetrik

Erkenntnis

- Mit Walk-Forward Evaluierung verschlechtert das Performance wie erwartet.

Historischer Vergleich: mögliche konservative ML

2026-06-07 bis 2026-06-29: Verdacht auf konservatives Modell von SMARD



2025-10-01 bis 2026-01-01: Verdacht statistisch widerlegt

Model	Prediction $\leq$ real	Bias (MWh)	MAE (MWh)
SMARD	56,8 %	+ 1868	1868
Standard-LightGBM	57,7 %	- 513	1567
Conservative LightGBM	14,9 %	+ 2359	2751

Nutzen der GUI

- Anfang und Ende der Zeit für die Vorhersage.
- Abweichungsvergleich: Feiertage und Ferienzeiten auswählen
- Vergleich mit SMARD Prognose
- Modellauswahl
 - LightGBM
 - XGBoost

MAE

Primäre Metrik

RMSE

Nebenmetrik

Erkenntnis

- Visualisierung trägt zu besserer Übersicht bei. Statistische Werte basieren auf großen Datenmengen sind jedoch entscheidend.
- Bei Bedarf kann asymmetrische Verlustfunktion in den Modelle einbauen, um die Unterschätzungen zu reduzieren für die Produktionplanungssicherheit.

Fazit und Folgeprojekt

Projektfazit

- Das Portfolio-Projekt nutzt echte Daten, Pipeline, Modellvergleich und Demo-App.
- Lag-/Rolling-Features sind der zentrale Performance-Treiber.
- XGBoost/LightGBM sind derzeit die stärksten Modelle.
- Der SMARD-Vergleich macht das Ergebnis praxisnah.
- Visualisierung trägt die Dateneinsicht bei. Statistische Analyse ist jedoch entscheidend
- Automatische ETL Pipeline verbessert die App-Reaktion und die Datenkonsistenz
- Walk-Forward Funktion für historische Vorhersage entspricht der Datenverfügbarkeit
- Schulferien und Ferienratio als neue Features

Verbesserungspotential

- Mehr Features aus SMARD einbeziehen
- Arbeitsfreie Tagesblöcke
- Schulferien Abstände (vor und nach) zu Feiertage hinzufügen
- Industrieproduktionsindex testen.

To be continued: **stündliche Strompreis-Vorhersage**
Strompreis mit Stromverbrauch, PV Erzeugungs- und Windenergieproduktion-Vorhersage prognostizieren