

Flugzeugturbinen – Predictive Maintenance mit Machine Learning


Vorhersage der Remaining Useful Life (RUL) von Turbofan-Triebwerken anhand von NASA-C-MAPSS-Sensordaten

- ◆ End-to-End Machine-Learning-Projekt
- ◆ Feature Engineering und Hyperparameter-Tuning
- ◆ Interaktives Streamlit-Dashboard zur Analyse und Visualisierung


Projekt – Ziel & ML Pipeline

Ziel des Projekts ist die zuverlässige Vorhersage der verbleibenden Lebensdauer (Remaining Useful Life, RUL) von Flugzeugtriebwerken, um Wartungen frühzeitig planen und ungeplante Ausfälle vermeiden zu können.

Machin Learning Pipeline




RUL Verteilung der vier Datensätze



Erkenntnisse

- Die vier Datensätze unterscheiden sich hinsichtlich Betriebsbedingungen und Fehlermodi.
- Die RUL-Verteilungen weisen unterschiedliche Charakteristika auf.
- Ohne Begrenzung dominieren sehr große RUL-Werte das Training.
- Sensorwerte zeigen bereits früh deutliche Veränderungen vor dem Ausfall.
- Diese Beobachtungen bilden die Grundlage für das spätere Feature Engineering.

Modellvergleich XGBoost vs LightGBM



Model	MAE	RMSE	R ²
XGBoost	18,69	25,96	0,74
Tuned LightGBM	18,30	25,54	0,75
Tuned XGBoost	18,07	25,45	0,75
XGBoost + RUL cap 150	18,30	24,64	0,77

Erkenntnisse


- Beide Gradient-Boosting-Modelle liefern gute Ergebnisse.
- Hyperparameter-Tuning verbessert die Vorhersagequalität zusätzlich.
- Die Unterschiede zwischen beiden Modellen sind gering.
- LightGBM überzeugt durch hohe Geschwindigkeit und Effizienz, XGBoost durch robuste Leistung über verschiedene Datensätze.

Fazit

Beide Modelle eignen sich für Predictive-Maintenance-Anwendungen auf Basis tabellarischer Sensordaten.

RUL Capping Experiment

Optimalen max_RUL bestimmen




max_rul	MAE	RMSE	R²
75	30,24	42,73	0,30
100	22,01	31,64	0,62
125	18,69	25,96	0,74
150	18,30	24,64	0,77
175	19,27	25,59	0,75
200	20,48	27,21	0,72
250	22,15	30,22	0,65
None	23,58	33,09	0,58

Erkenntnisse

- Sehr hohe RUL-Werte erschweren das Lernen relevanter Degradationsmuster.
- Durch das Begrenzen der maximalen RUL (RUL Clipping) wird das Modell auf den interessanten Bereich fokussiert.
- Ein moderates Capping verbessert die Modellstabilität und reduziert den Vorhersagefehler.
- Zusätzlich wurden zeitabhängige Merkmale wie Sensoränderungen und Trends berücksichtigt.

Feature Importances







Erkenntnisse

- Nur ein Teil der Sensoren trägt wesentlich zur Vorhersage bei.
- Insbesondere besitzen die Sensoren wie Sensor 11, 13 und 15 (je nach Analyse auch weitere) eine hohe Aussagekraft.
- Aus wichtigen Sensoren wurden zusätzliche Trend-Features ($\Delta 1$, $\Delta 5$ usw.) erzeugt.
- Dadurch konnte die Modellleistung weiter verbessert werden.

Nutzen

- Die Analyse erhöht die Interpretierbarkeit und reduziert unnötige Merkmale.

Vergleich Vorhergesagte vs. tatsächliche RUL



Erkenntnisse

- Die Modelle folgen dem tatsächlichen Alterungsverlauf der Triebwerke sehr gut.
- Kleine Abweichungen treten hauptsächlich bei komplexen Degradationsverläufen auf.
- Das RUL-Capping verhindert unrealistisch hohe Prognosen und stabilisiert die Vorhersagen.

Interpretation

- Die Ergebnisse zeigen eine gute Generalisierung auf bislang unbekannte Testdaten.

Entwicklung wichtiger Sensorwerte über die Lebensdauer

☒ Most critical engines
 ☐ Best predictions
 ☐ Worst predictions


	dataset_id	unit_nr	true_RUL	predicted_RUL	abs_error
570	FD001	34	7	5.7	1.3
549	FD001	31	8	17.5	9.5
586	FD001	81	8	6.3	1.7
529	FD001	68	8	11.6	3.6
444	FD001	82	9	7.2	1.8
409	FD001	42	10	22.1	12.1
574	FD001	76	10	12	2
553	FD001	35	11	8	3
381	FD001	66	14	13.4	0.6
334	FD001	56	15	15.7	0.7

Inspect one highlighted engine

FD001 / Unit 34

FD001 — Unit 34


True RUL	Predicted RUL	Absolute Error
7	5.7	1.3



Erkenntnisse

- Standardisierte Sensorwerte zeigen klare Trends während der Alterung.
- Einige Sensoren steigen kontinuierlich an, andere fallen mit zunehmendem Verschleiß.
- Die Kombination mehrerer Sensoren ermöglicht eine zuverlässigere Schätzung der Restlebensdauer als einzelne Messwerte.

Streamlit Dashboard



Funktionen

- Übersicht über Datensätze und Modellleistung
- Analyse einzelner Triebwerke (Engine Explorer)
- Visualisierung wichtiger Sensorverläufe
- Vergleich von vorhergesagter und tatsächlicher RUL
- Darstellung von Vorhersagefehlern zur Qualitätskontrolle



Mehrwert

Das Dashboard macht die Ergebnisse interaktiv nachvollziehbar und unterstützt die Interpretation der Modellvorhersagen.

Fazit und Ausblick

Projektfazit

- Erfolgreiche Entwicklung einer vollständigen Predictive-Maintenance-Pipeline.
- Durch gezieltes Feature Engineering und Hyperparameter-Tuning konnte die Vorhersagequalität deutlich verbessert werden.
- Das interaktive Dashboard erleichtert die Analyse einzelner Triebwerke und erhöht die Transparenz der Ergebnisse.

Ausblick

- Einsatz von LSTM- oder Transformer-Modellen für Zeitreihen.
- Unsicherheitsabschätzung der RUL-Prognosen.
- Echtzeit-Integration in industrielle Wartungssysteme.
- Erweiterung auf weitere Sensordaten und Anwendungsbereiche.